POLITECHNIKA ŚLĄSKA WYDZIAŁ INŻYNIERII MATERIAŁOWEJ I METALURGII

Kierunek: Informatyka Przemysłowa

Rodzaj studiów: stacjonarne

PROJEKT INŻYNIERSKI Michał Ćwiękała

INTEGRACIA JAVA Z MS EXCEL INTEGRATING JAVA WITH MS EXCEL

Kierujący projektem: Recenzent:

Dr inż. Adrian Smagór Dr Adam Kachel

Promotor merytoryczny: Dr inż. Marcin Blachnik

Spis treści

1.	1. Wstęp	3
2.	2. Cel i zakres pracy	4
3.	3. Możliwe narzędzia integracji MS Excel i Java	5
	3.1. Możliwości rozbudowy	5
	3.2. Dostępne rozwiązania:	5
	3.2.1. VBA	5
	3.2.2Net	6
	3.2.3. Java	6
	3.3. Wybór technologii	7
	3.3.1. Most DCOM - j-Interop	7
	3.3.2. Biblioteka XLLoop	8
	3.3.2.1. Zastosowanie	8
	3.3.2.2. XLLoop składa się z dwóch głównych k	komponentów:8
4.	4. RapidMiner	10
5.	5. Szczegóły implementacyjne projektu	12
	5.1. Budowa projektu	12
	5.2. Wykorzystane Biblioteki	13
	5.3. Interfejs użytkownika - GUI	13
	5.4. Tworzenie procesu w RapidMiner'ze	16
	5.5 Charáb deistaria	
	5.5. Sposób działania	16
	5.6. Główne klasy	
	•	18
6.	5.6. Główne klasy	
	5.6. Główne klasy	

1. Wstęp

W dzisiejszym skomputeryzowanym świecie biznesowym praca z arkuszem kalkulacyjnym to podstawa w każdej firmie i instytucji, niezależnie od branży. Microsoft Excel to najpopularniejszy na rynku program służący do dokonywania obliczeń zestawionych w formie tabelarycznej. Dostarcza on funkcje matematyczne, finansowe, bazodanowe oraz zapewnia półautomatyczne powtarzanie pisanych formuł.

Excel został napisany początkowo w języku C, a następnie wprowadzono do niego dużo modyfikacji z C++. Wspiera developerów korzystających z C#, który został również stworzony przez Microsoft. Jednak najbardziej popularnym językiem programowania od wielu lat pozostaje Java.

Jan 2016	Jan 2015	Change	Programming Language	Ratings	Change
1	2	^	Java	21.465%	+5.94%
2	1	~	С	16.036%	-0.67%
3	4	^	C++	6.914%	+0.21%
4	5	^	C#	4.707%	-0.34%
5	8	^	Python	3.854%	+1.24%

Rys. 1.1. - Ranking najbardziej popularnych języków programowania na świecie wg. serwisu TIOBE.²

Zagadnienie integracji języka JAVA i MS Excel jest częstym problemem i trudno jednoznacznie określić który sposób jest najlepszy. Każde rozwiązanie oferuje inne możliwości. Niniejsza praca ma na celu zbadania możliwości integracji obu platform i zaproponować najlepsze rozwiązanie.

Technologia Java została stworzona przez firmę Sun Microsystems, jego podstawowe koncepcje zostały przejęte z języka C++ - składnia i słowa kluczowe oraz Samlltalk - maszyna wirtualna i zarządzanie pamięcią.³

3

¹ Computerworld: Polski Word 2.0 i Excel 4.0 [dostep 2009-01-31]

² http://www.tiobe.com/index.php/content/paperinfo/tpci/index.html [dostep 2016-01-13]

³ https://www.java.com/pl/about/ [dostep 2015-12-27]

2. Cel i zakres pracy

Niniejsza praca dyplomowa pod tytułem "Integracja Java z MS Excel" ma na celu zbadanie możliwości rozbudowy funkcjonalności programu Microsoft Excel 2007 poprzez wykorzystanie do tego celu modułów i bibliotek dostępnych dla platformy Java

Zakres pracy obejmuje:

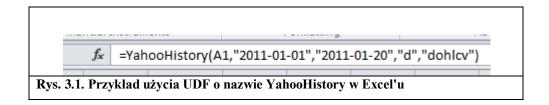
- dobór biblioteki pozwalającej na integrację platformy MS Excel z platformą języka Java,
- w oparciu o wybraną bibliotekę integracja platformy MS Excel z RapidMiner (biblioteką metod eksploracji danych)
- stworzenia wygodnego i przejrzystego interfejsu użytkownika wspierającego integrację procesów

3. Możliwe narzędzia integracji MS Excel i Java⁴

3.1. Możliwości rozbudowy

3.1.1. Excel User-Defined Function (UDF)

UDF jest to funkcja excelowa zdefiniowana przez użytkownika, która wykorzystuje komórki excelowe jako argumenty i zwraca jakąś wartość jako wynik obliczenia.



3.1.2. Makro

Excelowe makro zachowuje się inaczej - potrafi modyfikować wartości i style pomiędzy wieloma excelowymi komórkami i różnymi arkuszami. Używając makra możemy również tworzyć arkusze, menu, zmieniać kolor itd.



3.2. Dostępne rozwiązania:

3.2.1. VBA

Najprostszą drogą do stworzenia UDF'a w MS Excel jest Visual Basic for Applications - w skrócie VBA. Jest to język programowania oparty na Visual Basic'u dodany do aplikacji w

 $^{^4}$ http://computeraidedfinance.com/2011/11/26/what-shall-i-choose-for-implementing-an-excel-plugin-and-udf/ [dostep 2015-08-12]

pakiecie Microsoft Office, ale także i innych np. AutoCAD. Służy przede wszystkim do automatyzacji pracy z dokumentem. VBA można łatwo używać, lecz nie nadaje się w większych projektach, gdzie naprawialność i debuggowanie jest mocno ograniczone.

3.2.2..Net

Najbardziej podstawowymi technologiami służącymi do komunikacji z MS Excelem z użyciem C# jest Visual Studio Tools for Office (VSTO) i Primary Interop Assemblies (PIA). Oba te narzędzia wymagają dodatkowego czasu wykonywania programu na komputerze użytkownika. Do tworzenia UDF najbardziej przydatny jest Excel DNA, który również potrafi obsługiwać makra.

3.2.3. Java

Integracja Java z produktami Microsoft zawsze była problematyczna i wymagała zawiłych rozwiązań. W przypadku generowania plików excelowych przydatna jest biblioteka Apache POI, która pozwala na tworzenie nowych arkuszy, edycję stylów, kalkulacje itd. Niestety jest to komunikacja typu off-line, dostępna tylko z poziomu aplikazji Java. Natomiast aby osiągnąć komunikację on-line w arkuszu Excela, możemy wykorzystać:

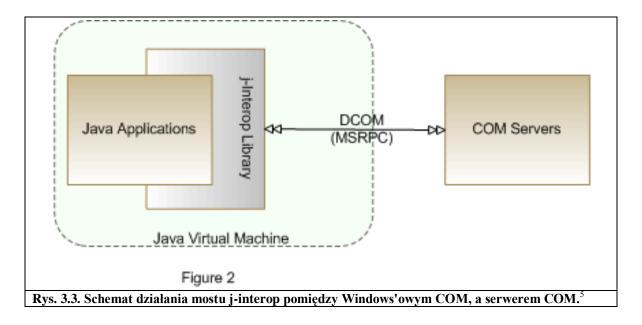
- integrację na poziomie makr wykorzystuje Excel COM interface. W internecie
 dostępnych jest wiele bibliotek wspierających mosty COM np. JACOB, com4j i
 J-Interop. COM (Component Object Model) jest standardem do tworzenia i projektowania interfejsów programistycznych na poziomie binarnym dla każdego
 modułu wprowadzonym przez Microsoft.
- integrację na poziomie UDF jest o wiele bardziej skomplikowana niż wezwanie COM. Dobrym open source'owym projektem jest XLLoop. Pozwala na integrację Excela z Java, C, Python, Ruby i wiele więcej. Minusem tego rozwiązania jest konieczność włączenia serwera XLLoop przez użytkownika.
- komunikację za pomocą web service'ów, w której platforma .Net pełni rolę pośrednika pomiędzy Java i Excel'em za pomocą protokołu SOAP

3.3. Wybór technologii.

3.3.1. Most DCOM - j-Interop

Praca w początkowej fazie zakładała komunikację z MS Excelem za pomocą mostu COM, gdyż jest najprostszą i najbardziej "naturalną" metodą z możliwych. Do projektu wybrano najpopularniejszy i zarazem najnowszy most COM - j-Interop (http://www.j-interop.org). Standardowe mosty COM wykorzystują do komunikacji natywny interfejs Java JNI (Java Native Interface), co znacznie utrudnia komunikację pomiędzy platformami. J-Interop wykorzystuje protokół DCOM umożliwiający efektywną, dwu-kierunkową i nienatywną komunikację.⁵

Niestety po pierwszych próbach wystąpiła duża ilość problemów związanych z bezpieczeństwem. Komputer na którym tworzony był projekt wyposażony był w system Windows 7 Home Premium i pakiet Office 2007. Po próbach konfiguracji serwisów, komponentów, ustawień domeny i serwera oraz modyfikacji firewalla, prace zostały wstrzymane. Ze względu na Politykę Bezpieczeństwa Microsoft wykorzystanie tej technologii w tym środowisku jest bardzo problematyczne. Biblioteka była rozwijana najintensywniej w latach 2006-2007 i nie zakłada najnowszych zabezpieczeń. Kolejną fazą projektu było wypróbowanie możliwości biblioteki XLLoop.



⁵ http://www.j-interop.org/introduction.html [dostep 2015-06-21]

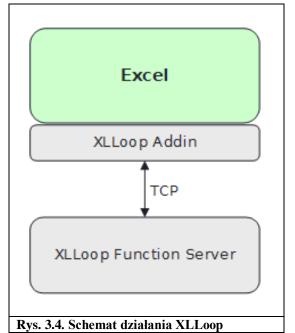
-

3.3.2. Biblioteka XLLoop⁶

XLLoop to open sourcowa biblioteka pozwalająca implementować Excelowe funkcje zdefiniowane przez urzytkownika (UDF - User-Defined Functions) na zcentralizowanym serwerze (serwerze funkcyjnym).

3.3.2.1. Zastosowanie

- Funkcje mogą być napisane w każdym języku (w tym Java, języki skryptowe itd.),
- Funkcje mogą być dodane szybko i dynamicznie bez konieczności restartowania Excela,



- Funkcje mogą być zarządzane oddzielnie i centralnie, co zapobiega kosztów zarządzania wieloma XLL'ami i gwarantuje wszystkim użytkownikom używanie tych samych funkcji,
- Dane mogą być dzielone pomiędzy excelowymi sesjami/użytkownikami (np. obecne ceny giełdowe mogą być przechowywane na pojedynczym serwerze i wszystkie sesje Excela mogą uzyskiwać te dane za pomocą przykładowej funkcji GetStock).

3.3.2.2. XLLoop składa się z dwóch głównych komponentów:

- Excelowy dodatek (XLL napisany w C++)
- Serwer i biblioteka napisana w Java (i w wielu innych językach)

-

⁶ http://xlloop.sourceforge.net/ [dostep 2015-11-12]

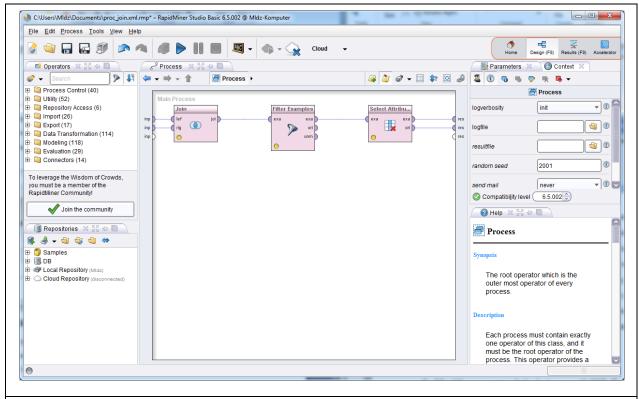
Dodatek i serwer komunikują się poprzez zwykłe oparte o schowek protokoły, wysyłające i odbierające (binarnie) zserializowane excelowe obiekty (nazywane xloper).

W modyfikacji JSON dodatek i serwer komunikują się ponad protokołami http(s), wysyłając i otrzymując JSON'owe zserializowane excelowe obiekty.

4. RapidMiner

RapidMiner to najczęściej używana open source'owa platforma do predykcyjnej analizy oraz eksploracji danych. Tworzony w nim kod generuje się za pośrednictwem intuicyjnego graficznego interfejsu użytkownika, który pomaga zaprojektować analizowany proces. RapidMiner posiada upublicznione biblioteki służące do rozszerzenia jego funkcjonalności, można je znaleźć na serwerze GitHub.com. Platforma jest otwarta do współpracy z mnóstwem źródeł danych w tym: Excel, Access, Oracle, IBM DB2, Microsoft SQL, Netezza Teradata, MySQL, Postgres, SPSS, Salesforce.com. RapidMiner umożliwia nowoczesną analizę w każdej skali, jest wręcz idealne dla Big Data.

RapidMiner jest programem, który nadaje się do współpracy z MS Excel i jest w stanie znacząco rozszerzyć jego możliwości. Jest napisany w Java i posiada możliwość wczytywania arkuszy Excel. Jednak w niniejszym projekcie funkcje Java mają być wykonywane z poziomu Excela - który potrafi obsługiwać przeciętny użytkownik.⁷

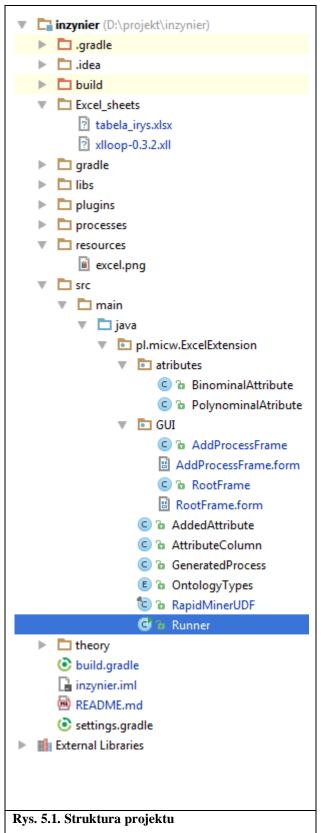


Rys. 4.1. Przykładowy proces w programie RapidMiner

⁷ https://rapidminer.com/ [dostep 2015-11-29]

Procesy w RapidMinerze, można eksportować i importować w formacie RMP (format dedykowany) oraz XML co umożliwia znaczną uniwersalność jak również możliwość wykorzystania w różnych projektach.

5. Szczegóły implementacyjne projektu



5.1. Budowa projektu

Projekt został stworzony w środowisku IntelliJ IDEA 15. Wykorzystuje Java SE Development Kit 8. Składa się z 9 klas i 1 typu wyliczeniowego. Posiada również 2 okna dialogowe:

- RootFrame odpowiada, za główne menu programu, zawiera instrukcję obsługi, przyciski służące do dodawania i usuwania procesów oraz wyświetla aktualnie załadowane procesy,
- AddProcessFrame odpowiada za dodanie nowego atrybutu przez użytkownika. Należy w nim podać nazwę projektu, lokalizację do procesu w formacie XML lub RMP oraz atrybuty (<u>o tej samej nazwie i</u> <u>typie co atrybuty w projekcie RapidMiner'a</u>).

Projekt zawiera 922 linie kodu napisanego w Java, 279 linii wygenerowanych przez pliki FORM i 269 linii w plikach Gradle. Aby zachować wysoką jakość kodu w projekcie użyto plugin'u CheckStyle i Find-Bugs, a analizy został użyty plugin Statistic.

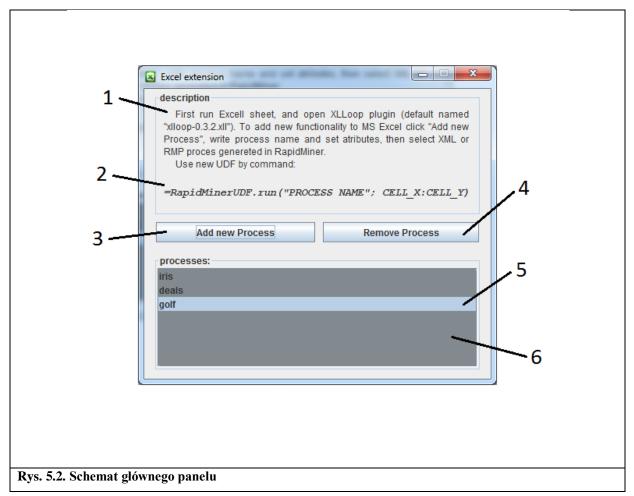
5.2. Wykorzystane Biblioteki

Do zbudowania projektu zostało użytych kilka plugin'ów napisanych w Gradle. Dzięki temu większość bibliotek została pobrana ze zdalnego repozytorium. Jedynie biblioteka corowa do RapidMinera, jak równierz XLLoop musiała zostać ręcznie ściągnięta i ustawiona w repozytorium lokalnym. Pluginy Gradle'owe zostały pobrane ze strony projektu RapidMiner na Github.com. Główne biblioteki:

- XLLoop 0.3.2,
- Rapidminer-studio-core 6.5.2,
- Swing interfejs graficzny,
- Awt interfejs graficzny i obsługa zdarzeń,

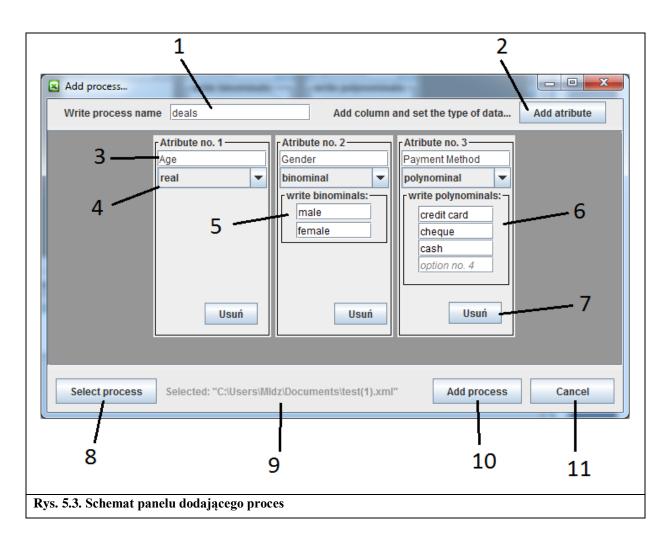
5.3. Interfejs użytkownika - GUI

Poniżej w sposób schematyczny przedstawiono podstawowe elementy konfiguracyjne stworzonego interfejsu użytkownika.



Legenda do rys. 5.1

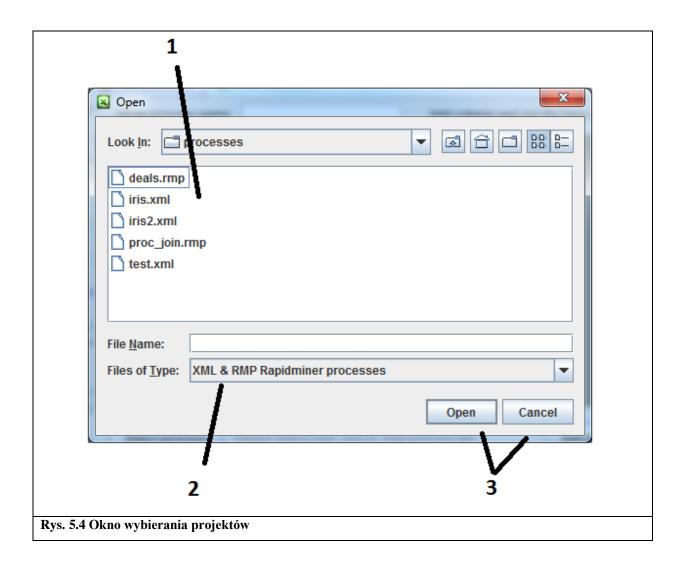
- 1) opis działania programu
- 2) funkcja wzorowa wywołująca dany skrypt w arkuszu Excel
- 3) przycisk służący do dodania nowego procesu
- 4) przycisk służący do usunięcia zaznaczonego procesu
- 5) zaznaczony proces
- 6) lista z aktualnie obsługiwanymi procesami



Legenda do rys. 5.2:

- 1) nazwa procesu,
- 2) przycisk generujący kolejny atrybut,
- 3) nazwa atrybutu (musi pokrywać się z nazwą w procesie),
- 4) rodzaj danych
- 5) zdefiniowane wartości binominal,

- 6) zdefiniowane wartości polynominal (opcje kolejno się generują),
- 7) przycisk umożliwiający usunięcie całego atrybutu,
- 8) przycisk pozwalający wybrać lokalizację
- 9) ścieżka do wybranego procesu
- 10) przycisk dodający proces
- 11) przycisk anulujący



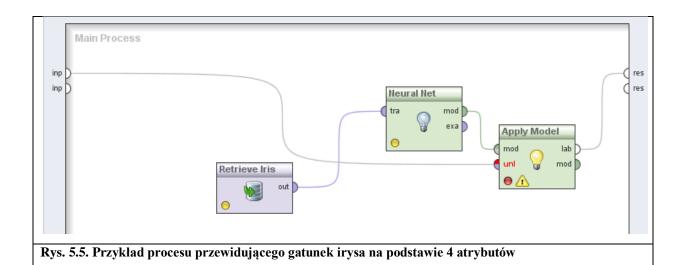
Legenda do rys 5.3:

- 1) dostępne procesy do wyboru
- 2) możliwe rozszerzenia procesu .xml oraz .rmp
- 3) przyciski wyboru

5.4. Tworzenie procesu w RapidMiner'ze

Tworzone procesy w RapidMiner'ze mogą posiadać wiele wejść. Dzięki bogatemu interfejsowi graficznemu użytkownik jest wstanie w łatwy sposób analizować przekazywane dane.

W poniższym przykładzie procesu sieć neuronowa jest uczona za pomocą zbioru danych "Retrive Iris". Następnie dane przychodzące na wejście są analizowane przez sieć i funkcja "Apply Model" decyduje o wyniku predykcji.



ExampleSet (150 examples, 2 special attributes, 4 regular attributes) id Row No. label a1 a3 a4 a2 id_1 Iris-setosa 5.100 3.500 1.400 0.200 2 id 2 Iris-setosa 4.900 3 1.400 0.200 id 3 3 Iris-setosa 4.700 3.200 1.300 0.200 4 id_4 Iris-setosa 4.600 3.100 1.500 0.200 5 id_5 Iris-setosa 3.600 1.400 0.200 Rys. 5.6. Przykładowy zbiór danych uczących sieć neuronową

5.5. Sposób działania

Klasa Runner posiada statyczną metodę główną main która odpowiedzialna jest za uruchomienie programu. W początkowej fazie wykorzystywana jest biblioteka XLLoop, aby utworzyć serwer nasłuchujący przesyłane pakiety protokołu TCP przez dodatek uruchomiony w Excel'u.

W międzyczasie odpalany jest kolejny wątek odpowiedzialny za wywołanie głównego okna - RootFrame - w którym użytkownik może zdefiniować własne procesy. Należy pamiętać, że atrybuty w ustawianym procesie muszą być identyczne z atrybutami definiowanymi w procesie RapidMiner'a. Możliwe są 3 typy danych:

- real wartości liczbowe,
- binominal wartości dwuargumentowe np. typu prawda/fałsz,
- polynominal typ wyliczeniowy np. rodzaje kolorów

Po zdefiniowaniu procesów, należy uruchomić arkusz MS Excel z danymi do przetworzenia i uruchomić dodatek "xlloop-0.3.2.xll". W tym momencie przesyłana jest do Excela metoda run z klasy RapidMinerUDF. Można ją wywołać przykładowo poprzez wywołanie:



Metoda run w pierwszej kolejności sprawdza nazwę procesu i pobiera ją z Listy wygenerowanych procesów. Dzięki danym w liście możliwe jest utworzenie ExampleSet'a, który obsługuje zbiór wejściowych danych do procesów. W przypadku wartości binominal i polinominal tworzone są mapy zamieniające wartość Integer na dany typ String. Po wygenerowaniu ExampleSet'a pobierane są wejścia procesu, a następnie pobieramy wygenerowany wynik. W przypadku wyniku w wielu komórkach należy użyć w arkuszu Excel kombinacji "ctrl + shift + enter" odpowiadającą za rozbudowane funkcje.

SUMA ▼ (× ✓ f _x =RapidMine					MinerUDF.r	UDF.run("iris";B8:E8)			
4	Α	В	С	D	Е	F	G	Н	I
1	id	a1	a2	a3	a4	Iris-setosa	lris-versicolor	Iris-virginica	Prediction
2	id_1	4,4	2,9	1,4	0,2	0,99222224	0,007777447	3,1278E-07	Iris-setosa
3	id_2	4,9	3,1	1,5	0,1	0,993543304	0,006456431	2,6478E-07	Iris-setosa
4	id_3	5,4	3,7	1,5	0,2	0,994661609	0,005338168	2,2381E-07	Iris-setosa
5	id_4	4,8	3,4	1,6	0,2	0,993870395	0,006129351	2,5435E-07	Iris-setosa
6	id_5	6,3	2,9	5,6	1,8	8,49089E-05	0,004418658	0,99549643	Iris-virginica
7	id_6	5,6	2,5	3,9	1,1	0,007990046	0,990929293	0,00108066	lris-versicolor
8	id_7	5,9	3,2	4,8	1,8	=RapidMinerU	DF.run("iris";B8	3:E8)	
9	id_8	5,3	3,7	1,5	0,2				
10	id_9	5	3,3	1,4	0,2				
11	id 10	7	22	17	1 /				

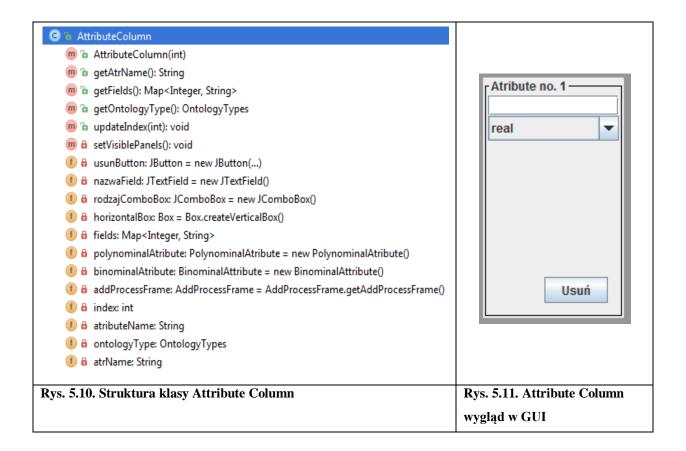
Rys. 5.9. Kod programu przekazywany do konsoli.

- Linia 1 program nasłuchuje portu nr 5454. Oczekuje na przesłanie pakietów TCP.
- Linie 2-3 został dodany proces przez użytkownika.
- Linie 4-6 Użytkownik włączył dodatek do Excela. Następuje inicjalizacja biblioteki xlloop, a następnie przekazywana jest statyczna metoda RapidMinerUDF.run
- Linia 7 Została wywołana nowa funkcjonalność. Dane są przekazywane do aplikacji napisanej w Java i są poddane analizie

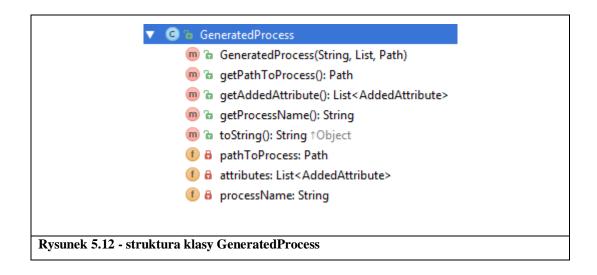
Linie 18-25 - dane zostają zwrócone wraz z predykcją

5.6. Główne klasy

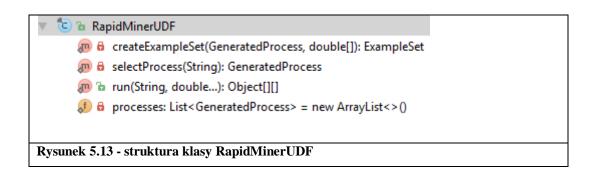
Atribute column - klasa odpowiedzialna za tworzenie obiektu poszczególnego
atrybutu. Posiada unikalny index i może przybierać różne typy (użyty został
enum OntologyType). Jest częścią Listy w klasie AddProcessFrame. Przy ontologii binominal i polinominal uzupełniana jest mapa fields, aby poszczególnym
opcjom przyporządkować odpowiedni index. Natomiast przy ontologii real mapa
jest domyślnie pusta.



GeneratedProcess - klasa odpowiedzialna za tworzenie obiektów skonfigurowanych projektów. Zawiera wszystkie kluczowe informacje niezbędne do uruchomienia danego procesu.



 <u>RapidMinerUDF</u> - klasa, która przekazuje wszystkie swoje metody publiczne, statyczne do klasy ReflectFunctionHandler w XLLoop. Jedyną taką metodą jest run. Reszta służy do obsługi tej metody.



5.7. Sposób tworzenia

Biblioteka XLLoop wykorzystuje w dużej mierze programowanie proceduralne - najważniejsze metody są statyczne i są wywoływane w klasie Runner. Podobnie bliblioteka Swing i AWT opierają się na programowaniu proceduralnym, gdzie poszczególne parametry określa się metodami typu get i set, a wartości przekazuje się przez metody statycze.

W związku z tym podczas tworzenia projektu utrudnione było projektowanie obiektowe oraz wykorzystywanie powszechnie znanych wzorców projektowych.

6. Wnioski i podsumowanie

W informatyce bardzo często mamy do czynienia z kilkoma rozwiązaniami dotyczących tych samych problemów. Autorzy danych produktów, używając często własnych implementacji, co może dodatkowo utrudnić proces integracji. Z punktu widzenia developera, który musi korzystać z rozwiązań wielu technologii konieczna jest wiedza i doświadczenie w tej dziedzinie. Kluczowym zagadnieniem są protokoły służące do ujednolicenia komunikowanych danych.

Microsoft wprowadzając na rynek coraz nowsze wersje pakietu Office wciąż nie wspiera technologii Java, z powodów ekonomicznych. Jednak ich odpowiednik - C# nie jest w stanie w znaczący sposób wyróżnić się na tle innych języków wysokiego poziomu.

Każdy projekt różni się wytycznymi i w zależności od wymagań, architektury, funkcjonalności czy trendów wymaga zastosowania odpowiedniej technologii. Każdy projekt jest unikalny i należy do niego podchodzić indywidualnie szukając możliwie najprostszych i najbardziej efektywnych rozwiązań. Dlatego warto rozwijać się w wielu dziedzinach oraz poznawać alternatywne rozwiązania. Wraz z postępem czasu potrzeba integracji wielu systemów staje się coraz większa.

7. Literatura

- 1) Computerworld: Polski Word 2.0 i Excel 4.0 wydanie 2009-01-31
- 2) http://www.tiobe.com/index.php/content/paperinfo/tpci/index.html, 2016-01-13
- 3) https://www.java.com/pl/about/, 2015-12-27
- 4) http://computeraidedfinance.com/2011/11/26/what-shall-i-choose-for-implementing-an-excel-plugin-and-udf/ , 2015-08-12
- 5) http://www.j-interop.org/introduction.html, 2015-06-21
- 6) http://xlloop.sourceforge.net/, 2015-11-12
- 7) https://rapidminer.com/, 2015-11-29

8. Spis rysunków

- Rys. 1.1. Ranking najbardziej popularnych języków programowania na świecie wg. serwisu TIOBE. Strona 3
- Rys. 3.1. Przykład użycia UDF o nazwie YahooHistory w Excel'u. Strona 4
- Rys. 3.2. Przykład wykorzystania makra. Strona 5
- Rys. 3.3. Schemat działania mostu j-interop pomiędzy Windows'owym COM, a serwerem COM. Strona 7
- Rys. 3.4. Schemat działania XLLoop. Strona 7
- Rys. 4.1. Przykładowy proces w programie RapidMiner. Strona 9
- Rys. 5.1. Struktura projektu. Strona 10
- Rys. 5.2. Schemat głównego panelu. Strona 11
- Rys. 5.3. Schemat panelu dodającego proces. Strona 12
- Rys. 5.4 Okno wybierania projektów. Strona 13
- Rys. 5.5. Przykład procesu przewidującego gatunek irysa na podstawie 4 atrybutów. Strona 14
- Rys. 5.6. Przykładowy zbiór danych uczących sieć neuronową. Strona 14
- Rys. 5.7. Przykład wywołania funkcji iris dla argumentów B8:E8. Strona 15
- Rys. 5.8. Przykład wywołania procesu iris w MS Excel 2007. Strona 15
- Rys. 5.9. Kod programu przekazywany do konsoli. Strona 16
- Rys. 5.10. Struktura klasy Attribute Column. Strona 17
- Rys. 5.11. Attribute Column wygląd w GUI. Strona 17
- Rys. 5.12. struktura klasy GeneratedProcess. Strona 17
- Rys. 5.13. struktura klasy RapidMinerUDF. Strona 18